Query Control for Fluent Query Focused Summarization

류상원
아주대학교
Ajou University
ryuuuuuuuu@ajou.ac.kr

손경아
아주대학교
Ajou University
kasohn@ajou.ac.kr

요약문

본 논문에서는 사용자의 니즈에 따라 요약을 하는 Query-focused Summarization(QFS) task 연구를 진행한다. QFS 란, 입력된 쿼리를 중심으로 추상적 요약을 하는 연구이다. 2020 년까지는 입력 문서의 중요도를 파악한 후 중요도가 높은 문장들을 추출하는 추출적 요약이 요약 task 의 주를 이루었다. 하지만 추출적 요약의 경우 원문에 있는 내용을 그대로 사용하기 때문에 요약문의 내용이 자연스럽지 않을 수 있다. 보다 최근에는 모델이 입력 문서를 이해하고 새로 요약문을 생성하는 추상적 요약 중심으로 연구가 진행되었고 모델이 새로 요약문을 생성하기 때문에 더 자연스럽고 좋은 요약문을 생성할 수 있다. 특히 QFS 의 경우 사용자의 니즈에 따라 요약하기 때문에 실생활에 사용할 수 있는 실용적인 기법이며 자연스러운 요약문 생성이 매우 중요하다. 하지만 현재 좋은 ROUGE score 를 내는 모델들이 human evaluation 관점에서는 좋지 않은 성능을 내는 것을 볼 수 있었다. 따라서, 이번 연구에서는 human evaluation 중 fluency 를 향상시키기 위한 방법을 제안한다.

주제어

자연어 처리, 요약, QFS

1. 서 론

1.1 배경

QFS 분야는 controllable summarization 분야 중 하나로 control token 으로 쿼리를 사용하는 task 를 뜻한다. 대표적인 controllable summarization 모델인 CTRLsum[1] 이후에 본격적인 QFS 연구가 진행되었다. QFS 분야에서 좋은 성능을 내는 모델 중의 하나는 SEGENC[2]이다. SEGENC 는 대표적인 QFS 모델인 DYLE[5], SUMMN[6] 보다 높은 ROUGE score 를 보이고 있지만 BART[3]보다도 낮은 human evaluation score 를 보인다. Human evaluation 지표 중에서 특히 fluency 가 낮은 것을 볼 수 있는데 QFS 에서는 단순히 Recall score 을 계산하는 ROUGE score 보다 human evaluation 이 더 중요하다. 따라서, ROUGE score 는 최대한 유지한 채, 더 자연스러운 요약문을 생성하는 것이 이 연구의 목표이다.

1.2 기존 모델의 문제점

기존의 SEGENC 모델의 human evaluation 점수가 낮은 이유를 3 가지 로 나누었다. 첫 번째로, 쿼리가 요약문에 그대로 포함된다는 점, 두 번째로, 동일한 단어 (쿼리에도 들어 있는 핵심 단어)가 반복하여 생성되는 점, 마지막으로 모르는 내용의 쿼리가 들어왔을 때, 쿼리를 요약문으로 생성한다는 점이었다. 첫 번째 문제점의 빈도가 가장 높았고 기존 모델의 human evaluation 을 해치는 주된 요인이었다. 결론적으로 모든 세그먼트가 쿼리와 합쳐지기 때문에 인코더에 학습되는 쿼리가 너무 많다는 점이 문제점이다. 따라서, 합치는 쿼리를 조절하는 세 가지 방식을 제안한다.

2. 본문

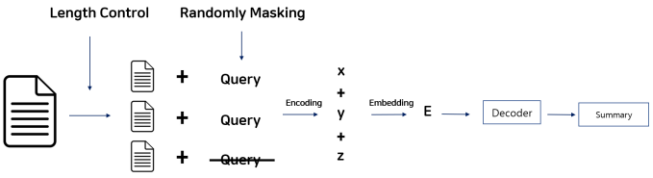

Figure 1 전체 모델 구조

실험은 총 3 가지를 진행하였다. 첫 번째로, 쿼리와 합치는 세그먼트의 길이를 조절하여 적당한 길이의 세그먼트 길이를 찾았고, 두 번째로, 쿼리와 합치는 세그먼트의 비율을 조절하여 쿼리를 너무 많이 학습하지 않도록 하였고, 마지막으로 쿼리 내부의 단어들을 랜덤하게 마스킹하여 쿼리 내부의 단어들 간의 연관성을 떨어뜨려, 쿼리가 요약문에 그대로 출력되지 않도록 하였다.

2.1 Control Segment Length

해당 모델에서는 입력 문서를 특정 크기의 세그먼트로 잘라 쿼리와 합친 후에 인코딩을 진행한다. 하지만 기존 모델에서는 모든 세그먼트를 쿼리와 합치기 때문에, 세그먼트의 길이를 조절하여 쿼리가 인코더에 학습되는 비율을 줄이는 실험을 진행하였다.

2.2 Randomly Concatenate Query

모든 세그먼트와 쿼리를 합친 후에 인코딩을 진행하기 때문에 쿼리를 너무 많이 학습한다고 판단했기 때문에, 랜덤하게 쿼리와 세그먼트를 합칠 수 있게 하였다. 무작위로 세그먼트를 선택한 후에 선택한 세그먼트만 쿼리와 합쳐서 학습하였다.

2.3 Randomly Masking Query

쿼리가 그대로 요약문에 나오는 경우가 많았기 때문에, 쿼리 문장 내의 단어들 간의 어텐션 값이 너무 높게 계산되었다고 판단이 되었다. 따라서 쿼리 문장의 단어들을 랜덤하게 마스킹하여 쿼리 문장 내의 단어들의 연관성을 줄일 수 있도록 하였다.

3. 실험결과

3.1 Control Segment Length

세그먼트의 길이를 16 부터 시작하여 1024 까지 진행을 하였는데, 세그먼트 길이가 너무 작을 경우, 요약문이 쿼리와 동일하게 생성되었다. 세그먼트 크기를 점점 늘릴 경우, 요약문이 더 복잡하고 전체 문서 내용을 잘 포함하는 요약문이 생성이 되었고, 세그먼트 길이가 512 가 되었을 때부터 쿼리가 요약문에 포함되지 않기 시작했다.

표 1. 세그먼트 길이에 따른 요약문

	요약문
Query	Summarize the whole meeting.
32	Summarize the whole meeting.
64	Summarize the whole meeting. There were a number of issues that came up during the meeting. One of them was the issue of child abuse in the United Kingdom. I think it is important to remember that child abuse is a crime in the UK. I think that it is a serious
256	Summarize the whole meeting. Barry Hughes, Chief Justice of the Court of Appeal of England and Wales, said : " I think it is important to remember that there is a difference between a criminal offence and a civil offence. …
512	The meeting was about the Children, Young People and Education Committee's eleventh evidence session on the Children (Abolition of Defense of Reasonable Punishment) (Wales) Bill. The meeting started with Barry Hughes, …
1024	This was the Children, Young People and Education Committee's eleventh evidence session on the Children (Abolition of Defense of Reasonable Punishment) (Wales) Bill. First, Barry Hughes, ...

3.2 Randomly Concatenate Query

랜덤하게 세그먼트를 선택한 후에 선택된 세그먼트만 쿼리와 합쳐서 학습하였다. 선택한 세그먼트의 양은 50%, 80%, 95%를 사용하였다. 50%와 80%의 세그먼트만을 쿼리와 합칠 경우, 쿼리가 너무 적게 학습이 되어서 쿼리와 상관없는 제네릭한 요약문이 출력 되었다. 95%에서는 쿼리가 요약문에 그대로 나온다는 단점이 사라졌다. 하지만 요약문을 읽어보면, 문법에 조금 맞지 않는 문장이 생성이 되었다.

표 2. 쿼리와 결합하는 세그먼트 비율에 따른 요약문

	요약문
Query	Population of seoul
50%	Seoul, officially known as the Seoul Special City, is the capital and largest metropolis of South Korea. According to the 2020 census, Seoul has a population of 9.9 million people, ...
80%	The capital and largest metropolis of South Korea. According to the 2020 census, Seoul has a population of 9.9 million people, and forms the heart of the Seoul Capital Area…
95%	The Republic of Korea capital is located

	in South Korea. According to the 2020 census, it has a population of 9.9 million people, and forms the heart of the Seoul Capital Area with the surrounding Incheon metropolis and Gyeonggi province.

3.3 Randomly Masking Query

마지막으로 쿼리 문장 내부의 단어들을 랜덤하게 마스킹하는 실험을 진행하였다. 마스킹의 경우 전체 토큰의 15%의 토큰을 마스킹하였고, 전체 마스킹의 80%는 [MASK] 토큰으로 대체하고 나머지는 랜덤 토큰으로 대체하여 마스킹을 진행하였다. 기존의 요약문에서는 쿼리가 그대로 생성되는 것에 반해, 쿼리에 마스킹을 하고 학습을 진행할 경우, 요약문에 쿼리가 그대로 생성되지 않고, 자연스러운 문장이 생성되었다. 세그먼트 길이를 512 와 1024 로 하였을 때 모두 기존의 문제점이 개선된 자연스러운 요약문이 생성되었다.

표 3. 쿼리 단어를 랜덤하게 마스킹한 요약문

Query	Population of seoul
No mask	capital of South Korea is located at 9.9 million people, and forms the heart of the Seoul Capital Area with the surrounding Incheon metropolis and Gyeonggi province.population of seoul
Masked	The capital of the Republic of Korea is Seoul. According to the 2020 census, Seoul has a population of 9.9 million people, and forms the heart of the Seoul Capital Area with the surrounding Incheon metropolis and Gyeonggi province.

3.4 ROUGE Score

QMSum [4]데이터셋을 사용하여 전체 실험의 ROUGE score 계산하였다.

표 4

	ROUGE-1	ROUGE-2	ROUGE-L
SEGENC	37.46	13.50	24.11
BART	31.87	9.08	27.50
DYLE	34.43	9.71	30.10
SUMMN	34.03	9.28	29.48
SEGENC-mask-512	36.48	12.68	23.37
SEGENC-mask-1024	36.68	12.74	23.09

ROUGE score 는 기존의 SEGENC 보다 0.8~1.0 정도 하락한 것으로 보인다. 하지만 요약 분야에서 ROUGE score 는 단순히 Recall 값을 계산하고 다의어와 같은 요약에 적합한 단어들을 평가하지 못하기 때문에 human evaluation 에 비해 중요성이 떨어진다. 따라서 기존 모델에서 fluency 가 높아졌다는 점에서 의미가 있다. 또한 다른 QFS 모델들(DYLE, SUMMN)보다 높은 ROUGE score 를 보인다.

4. 결론

Human evaluation 중에서 특히 fluency 가 낮았던 기존 모델에서 3 가지 실험 Control Segment Length, Randomly Concatenate Query, Randomly Masking Query 를 통해서 자연스러운 요약문을 생성했다. 기존 모델에서는 쿼리가 요약문에 그대로 생성되었지만, 우리가 제안하는 SEGENC-mask-512 에서는 쿼리가 요약문에 포함되지 않고 자연스러운 요약문이 생성되었다. 반면에 ROUGE score 가 약간 떨어진 것으로 보이는데 이 부분이 아쉬웠다. 앞으로의 연구에서 자연스러운 요약문을 유지한 채 ROUGE score 를 향상시키는 연구를 진행할 계획이다.

사사의 글

본 연구는 2022 년 과학기술정보통신부 및 정보통신기획평가원의 SW 중심대학사업의 연구결과로 수행되었음"(2022-0-01077)

참고 문헌

1. Junxian He, Wojciech Kryściński, Bryan McCann, Nazneen Rajani, Caiming Xiong. CTRLsum: Towards Generic Controllable Text Summarization. arXiv 2020
2. Jesse Vig, Alexander R. Fabbri, Wojciech Kryściński, Chien-Sheng Wu, Wenhao Liu.

Exploring Neural Models for Query-Focused Summarization. NAACL 2022

3. Mike Lewis, Yinhan Liu, Naman Goyal, Marjan Ghazvininejad, Abdelrahman Mohamed, Omer Levy, Ves Stoyanov, Luke Zettlemoyer. BART: Denoising Sequence-to-Sequence Pre-training for Natural Language Generation, Translation, and Comprehension. ACL 2020
4. Ming Zhong, Da Yin, Tao Yu, Ahmad Zaidi, Mutethia Mutuma, Rahul Jha, Ahmed Hassan Awadallah, Asli Celikyilmaz, Yang Liu, Xipeng Qiu, Dragomir Radev. QMSum: A New Benchmark for Query-based Multi-domain Meeting Summarization. NAACL 2021
5. Ziming Mao, Chen Henry Wu, Ansong Ni, Yusen Zhang, Rui Zhang, Tao Yu, Budhaditya Deb, Chenguang Zhu, Ahmed H. Awadallah, Dragomir Radev. DYLE: Dynamic Latent Extraction for Abstractive Long-Input Summarization
6. Yusen Zhang, Ansong Ni, Ziming Mao, Chen Henry Wu, Chenguang Zhu, Budhaditya Deb, Ahmed Awadallah, Dragomir Radev, Rui Zhang. SUMMN：A Multi-Stage Summarization Framework for Long Input Dialogues and Documents