질의 제어를 통한 자연스러운 질의 중심 텍스트 요약

류상원O 손경아
아주대학교
ryuuuuuuuu@ajou.ac.kr, kasohn@ajou.ac.kr

Query Control for Fluent Query Focused Summarization

Sangwon RyuO Kyung-Ah Sohn
Ajou University

요 약

본 연구에서는 자연스러운 질의 중심 텍스트 요약을 위한 방법을 제안한다. 기존의 질의 중심 텍스트 요약문에는 사용자의 질의가 그대로 요약문에 출력되어 자연스럽지 않은 어색한 요약문이 생성된다. 질의가 요약문에 출력되지 않는 자연스러운 요약문을 생성하기 위해 질의와 결합하는 세그먼트의 길이를 조절하고, 세그먼트와 결합하는 질의의 비율을 랜덤하게 조절하고, 질의의 단어들을 랜덤하게 마스킹하는 방법을 제안한다. 제안한 방법을 통해 ROUGE 점수는 유지한 채 자연스러운 요약문을 생성하였다.

1. 서 론

질의 중심 요약이란, 입력된 질의를 중심으로 추상적 요약을 하는 연구이다. 요약 분야는 크게 추출적 요약과 추상적 요약으로 나뉘는데, 해당 모델에서는 추상적 요약을 사용한다. 2020년까지는 입력 문서의 중요도를 파악한 후 중요도가 높은 문장들을 추출하는 추출적 요약이 요약 분야의 주를 이루었다. 하지만 추출적 요약의 경우 원문에 있는 내용을 그대로 사용하기 때문에 요약문의 내용이 자연스럽지 않을 수 있다. 보다 최근에는 모델이 입력 문서를 이해하고 새로 요약문을 생성하는 추상적 요약 중심으로 연구가 진행되었고 모델이 요약문을 새로 생성하기 때문에 더 자연스럽고 좋은 요약문을 생성할 수 있다. 특히 질의 중심 요약 분야의 경우 사용자의 니즈에 따라 요약하기 때문에 실생활에 사용할 수 있는 실용적인 기법이며, 따라서 자연스러운 요약문 생성이 매우 중요하다. 질의 중심 요약 모델을 평가할 때 요약문을 평가하는 평가 지표인 ROUGE 점수나 perplexity보다 사람이 직접 평가하는 인간 평가(human evaluation)가 더 중요하다. 하지만 현재 가장 높은 ROUGE 점수를 내는 모델인 SEGENC[1]이 인간 평가 중 특히 유창성(fluency)에서 좋지 않은 성능을 내는 것을 볼 수 있었다. 따라서, 이번 연구에서는 기존 모델의 유창성이 좋지 않은 이유를 찾아보고 유창성을 향상시키기 위한 방법 세 가지를 제안한다.

1.1 배 경

질의 중심 요약 분야는 제어 요약 분야 중 하나로 제어 토큰으로 질의를 사용하는 분야를 뜻한다. 제어 요약이란, 제어 토큰을 사용하여 해당 토큰을 중심으로 요약을 하는 요약 분야이다. 일반적으로 제어 토큰으로 객체, 길이, 질의, 의도 등을 사용하는데, 질의를 제어 토큰으로 사용할 경우, 질의 중심 요약이라 한다. 대표적인 제어 요약 모델인 CTRLsum[2] 이후에 본격적인 제어 요약 연구가 진행되었으며, 그 중에서도 질의 중심 요약 연구가 가장 활발하게 진행되고 있다. SEGENC는 질의 중심 요약 분야에서 가장 좋은 성능을 내는 모델 중에 하나이며, 대표적인 질의 중심 요약 모델인 DYLE[3]과 SUMMN[4]보다 높은 ROUGE 점수를 보이고 있다. 반면에 인간 평가에서는 낮은 성능을 보이고 있고 특히 인간 평가 중 유창성에서는 베이스 모델인 BART[5]보다도 낮은 점수를 보이고 있다. 질의 중심 요약 분야에서는 Recall 점수를 계산하는 ROUGE 점수보다 사람이 직접 평가하는 인간 평가가 더 중요하다. 따라서 ROUGE 점수는 최대한 유지한 채, 더 자연스러운 요약문을 생성하는 것이 본 연구의 목표이다.

1.2 기존 모델의 문제점

기존의 SEGENC 모델의 유창성이 낮은 이유를 3가지로 분석하였다. 첫 번째로, 질의가 요약문에 그대로 포함된다는 점, 두 번째로, 동일한 단어(질의에도 들어있는 핵심 단어)가 반복하여 생성된다는 점, 마지막으로 모르는 내용의 질의가 들어왔을 때, 질의를 요약문으로 생성한다는 점이었다. 첫 번째 문제점인 질의가 요약문에 그대로 포함되는 문제점의 빈도가 가장 높았고 SEGENC의 유창성을

해치는 주된 요인이었다. SEGENC 모델에서는 인풋 문서를 세그먼트로 잘라 각 세그먼트를 질의와 결합하여 학습하는데, 모든 세그먼트를 질의와 결합하기 때문에, 질의가 너무 많이 학습되기 때문에 요약문에 질의가 그대로 출력된다. 따라서, 해당 논문에서는 결합하는 질의를 조절하는 세 가지 방식을 제안한다.

표 1. 기존 모델의 문제점

Query	Population of seoul
SEGENC	capital of South Korea is located at 9.9 million people, and forms the heart of the Seoul Capital Area with the surrounding Incheon metropolis and Gyeonggi province.population of seoul

2. 본 문

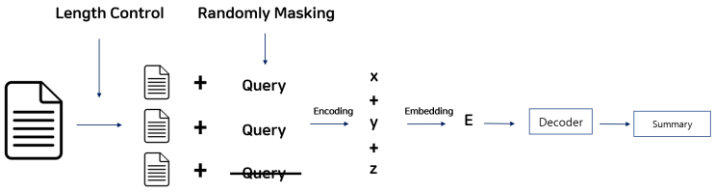

Figure 1. 전체 모델 구성

실험은 총 3가지를 진행하였다. 첫 번째로, 질의와 결합하는 세그먼트의 길이를 조절하여 질의와 결합하는 세그먼트의 길이를 변경하였고, 두 번째로 질의와 결합하는 세그먼트의 비율을 조절하여, 모든 세그먼트에 질의를 결합하는 것이 아닌 일부 세그먼트에만 질의를 결합할 수 있도록 하였고, 마지막으로 질의 내부의 단어들을 랜덤하게 마스킹하여 질의 내부의 단어들 간의 연관성을 떨어뜨려, 질의가 요약문에 그대로 출력되지 않도록 하였다.

2.1 세그먼트 길이 조절

해당 모델은 입력 문서를 특정 크기의 세그먼트로 잘라 질의와 합친 후에 인코딩을 진행한다. 따라서 세그먼트 크기를 정하는 것이 중요하다. 기존 모델에서 질의가 요약문에 그대로 출력되는 것이, 질의가 인코더에 과하게 학습되었다고 판단하였기 때문에, 질의와 결합하는 세그먼트의 길이를 늘려서 인코더에 학습하는 질의의 양을 줄이는 실험을 진행하였다.

2.2 세그먼트 비율 조절

기존 모델에서는 모든 세그먼트와 질의를 결합하여 인코딩을 진행한다. 모든 세그먼트에 질의를 결합하여 학습을 하면 질의가 인코더에 과하게 학습되기 때문에, 학습하는 질의의 양을 줄이기 위해 일부 세그먼트에는 질의와 결합하지 않고 그대로 학습하였다. 따라서 모든 세그먼트를 질의와 결합하는 것이 아니라, 특정 비율의 세그먼트만 질의와 결합하여 학습하였다.

2.3 질의 단어 랜덤 마스킹

모든 세그먼트에 질의를 결합하여 학습을 하기 때문에, 동일한 질의 문장이 과하게 학습이 되었고, 따라서 질의 문장 내의 단어들 간의 어텐션 값이 너무 높게 계산되었다. 따라서 질의 문장의 단어들을 랜덤하게 마스킹하여 질의 문장 내의 단어들 간의 연관성을 줄일 수 있도록 하였다. 마스킹의 경우 전체 토큰의 15%의 토큰을 마스킹하였고, 전체 마스킹의 80%는 [MASK] 토큰으로 대체하고 나머지는 랜덤 토큰으로 대체하여 마스킹을 진행하였다.

3. 실험 결과

3.1 세그먼트 길이 조절

세그먼트의 길이를 16부터 시작하여 1024까지 늘려가며 실험을 진행하였다. 세그먼트의 길이가 16처럼 너무 작을 경우, 요약문이 질의와 동일하게 생성되었다. 세그먼트의 크기를 점점 늘릴 경우, 요약문이 더 복잡하고 전체 문서 내용을 잘 포함하는 요약문이 생성되었다. 세그먼트 길이가 512가 되었을 때부터 질의가 요약문에 포함되지 않기 시작했다.

표 2. 세그먼트 길이에 따른 요약문

	요약문
Query	Summarize the whole meeting.
32	Summarize the whole meeting.
64	Summarize the whole meeting. There were a number of issues that came up during the meeting. One of them was the issue of child abuse in the United Kingdom. I think it is important to remember that child abuse is a crime in the UK. I think that it is a serious
256	Summarize the whole meeting. Barry Hughes, Chief Justice of the Court of Appeal of England and Wales, said : `` I think it is important to remember that there is a difference between a criminal offence and a civil offence.

	...
512	The meeting was about the Children, Young People and Education Committee's eleventh evidence session on the Children (Abolition of Defense of Reasonable Punishment) (Wales) Bill. The meeting started with Barry Hughes, ...
1024	This was the Children, Young People and Education Committee's eleventh evidence session on the Children (Abolition of Defense of Reasonable Punishment) (Wales) Bill. First, Barry Hughes, ...

3.2 세그먼트 비율 조절

특정 비율의 세그먼트를 선택한 후에 선택된 세그먼트만 질의와 결합하여 학습하였다. 세그먼트의 양은 전체 세그먼트의 50%, 80%, 95%의 비율을 사용하였다. 50%와 80%의 세그먼트를 질의와 결합하여 학습할 경우, 질의가 너무 적게 학습이 되어서 질의와 상관없는 포괄적인(generic) 요약문과 유사한 요약문이 출력되었다. 95%의 세그먼트를 질의와 결합하여 학습할 경우, 질의가 요약문에 그대로 나오는 단점을 개선하였다.

표 3. 질의와 결합하는 세그먼트 비율에 따른 요약문

	요약문
Query	Population of seoul
50%	Seoul, officially known as the Seoul Special City, is the capital and largest metropolis of South Korea. According to the 2020 census, Seoul has a population of 9.9 million people, ...
80%	The capital and largest metropolis of South Korea. According to the 2020 census, Seoul has a population of 9.9 million people, and forms the heart of the Seoul Capital Area...
95%	The Republic of Korea capital is located in South Korea. According to the 2020 census, it has a population of 9.9 million people, and forms the heart of the Seoul Capital Area with the surrounding Incheon metropolis and Gyeonggi province.

3.3 질의 단어 랜덤 마스킹

마지막으로 질의 문장 내부의 단어들을 랜덤하게 마스킹하는 실험을 진행하였다. 기존의 요약문에서는 질의가 그대로 생성되는 것에 반해, 질의에 마스킹을 하고 학습을 진행할 경우, 요약문에 질의가 그대로 출력되지 않고, 자연스러운 요약문이 생성되었다. 질의의 단어들을 랜덤하게 마스킹을 한 채로, 질의와 결합하는 세그먼트의 길이를 늘려 512와 1024로 학습하였을 때, 기존의 문제점이 개선된 자연스러운 요약문이 생성되었다.

Query	Population of seoul
No mask	capital of South Korea is located at 9.9 million people, and forms the heart of the Seoul Capital Area with the surrounding Incheon metropolis and Gyeonggi province.population of seoul
Masked	The capital of the Republic of Korea is Seoul. According to the 2020 census, Seoul has a population of 9.9 million people, and forms the heart of the Seoul Capital Area with the surrounding Incheon metropolis and Gyeonggi province.

3.4 ROUGE 점수

QMSUM[6] 데이터셋을 사용하여 전체 실험의 ROUGE 점수를 계산하였다.

	ROUGE-1	ROUGE-2	ROUGE-L
SEGENC	37.46	13.50	24.11
BART	31.87	9.08	27.50
DYLE	34.43	9.71	30.10
SUMMN	34.03	9.28	29.48
SEGENC (50%)	31.44	8.95	19.97
SEGENC (80%)	31.38	9.07	19.80
SEGENC (95%)	36.16	12.11	22.61
SEGENC-mask-256	34.90	10.99	22.23
SEGENC-mask-512	36.48	12.68	23.37
SEGENC-	36.68	12.74	23.09

mask-1024			
SEGENC (95%)-mask-512	35.58	11.59	22.61
SEGENC (95%)-mask-1024	35.26	11.62	22.50

ROUGE 점수는 기존의 SEGENC 모델보다 0.8~1.0 정도 하락하였고 다른 QFS 모델들인 DYLE과 SUMMN보다 2.0~2.6 정도 높은 성능을 보인다. 하지만 요약 분야에서 ROUGE 점수는 단순히 Recall 값을 계산하기 때문에 다의어와 같은 요약에 적합한 단어들을 평가하지 못한다. 따라서 ROUGE 점수는 인간 평가에 비해 중요성이 떨어진다. 본 연구에서는 ROUGE 점수를 유지한 채 인간 평가 중 하나인 유창성을 개선하였다.

4. 결론

본 연구에서는 기존 모델에서 인간 평가 중 유창성이 낮은 이유를 알아보고 3가지 실험을 통해 문제점을 개선하였다. 질의와 결합하는 세그먼트의 길이와 비율을 조절하여 질의가 인코더에 과하게 학습되는 문제점을 개선하였고, 질의 내부의 단어들을 랜덤하게 마스킹하여 단어 간의 연관성을 떨어뜨려, 질의가 요약문에 그대로 출력되는 문제점을 개선하였다. 우리가 제안하는 SEGENC-mask-512에서는 질의가 요약문에 포함되지 않고 자연스러운 요약문이 생성되었다. 앞으로의 연구에서 요약문의 자연스러움을 유지한 채 ROUGE 점수를 향상시키는 연구를 진행할 계획이다.

사사의 글

참고문헌

[1]Jesse Vig, Alexander R. Fabbri, Wojciech Kryściński, Chien-Sheng Wu, Wenhao Liu. Exploring Neural Models for Query-Focused Summarization. NAACL 2022

[2]Junxian He, Wojciech Kryściński, Bryan McCann, Nazneen Rajani, Caiming Xiong. CTRLsum: Towards Generic Controllable Text Summarization. arXiv 2020

[3]Ziming Mao, Chen Henry Wu, Ansong Ni, Yusen Zhang, Rui Zhang, Tao Yu, Budhaditya Deb, Chenguang Zhu, Ahmed H. Awadallah, Dragomir Radev. DYLE: Dynamic Latent Extraction for Abstractive Long-Input Summarization. ACL 2022

[4]Yusen Zhang, Ansong Ni, Ziming Mao, Chen Henry Wu, Chenguang Zhu, Budhaditya Deb, Ahmed Awadallah, Dragomir Radev, Rui Zhang. SUMMN : A Multi-Stage Summarization Framework for Long Input Dialogues and Documents. ACL 2022

[5]Mike Lewis, Yinhan Liu, Naman Goyal, Marjan Ghazvininejad, Abdelrahman Mohamed, Omer Levy, Ves Stoyanov, Luke Zettlemoyer. BART: Denoising Sequence-to-Sequence Pre-training for Natural Language Generation, Translation, and Comprehension. ACL 2020

[6]Ming Zhong, Da Yin, Tao Yu, Ahmad Zaidi, Mutethia Mutuma, Rahul Jha, Ahmed Hassan Awadallah, Asli Celikyilmaz, Yang Liu, Xipeng Qiu, Dragomir Radev. QMSum: A New Benchmark for Query-based Multi-domain Meeting Summarization. NAACL 2021