자연어 추론 형태를 적용한 퓨샷 러닝과 지도 대조 손실 함수

류상원*, 손경아
아주대학교

{ryuuuuuuuu, kasohn}@ajou.ac.kr

NLI Style few-shot learning with supervised contrastive loss

Sangwon Ryu, Kyung-Ah Sohn
Ajou Univ

요 약

본 논문은 기존의 자연어 추론 문제를 전이 학습을 통해 모델에 사용하고 지도 대조 손실을 적용하여 퓨샷 의도 분류 모델의 성능을 개선하고자 한다. 자연어 추론 문제 형태로 사전 학습을 진행하여 기존의 모델보다 일반화를 높이고 파인튜닝 단계에서 서포트셋을 자연어 추론 문제 형태에 맞게 변형하여 자연어 추론 문제로 사전 학습된 모델의 효과를 볼 수 있도록 한다. 또한 퓨샷 러닝 단계에서 지도 대조 손실을 사용하여 새로운 서포트셋을 기존의 방법보다 빠르게 적응할 수 있도록 학습하는 방법을 제안한다.

1. 서 론

본논문에서는 최근 의도 분류 모델 연구가 퓨샷에 관련하여 활발하게 연구가 진행됨에 따라 기존의 퓨샷 의도 분류 모델의 성능을 높이고자 한다. 퓨샷 의도 분류 모델의 성능을 높이기 위해서는 사전 학습 단계에서 충분한 일반화를 가지도록 학습하거나 파인튜닝 단계에서 새로운 의도를 빠르게 학습해야 한다. 본 모델에서는 자연어 추론 문제를 사전 학습에 사용하고 파인튜닝 단계에서 지도 대조 손실 함수를 사용한다. 자연어 추론 문제를 기본 RoBERTa[1] 모델의 사전 학습에 적용함으로써 모델을 더 일반화된 모델로 바꿀 수 있다는 것이 기존의 모델 DNNC[2]와 USLP[3]를 통해 증명되었다. DNNC 와 USLP 모두 사전 학습 단계에서 자연어 추론 문제 전이학습을 통해 성능을 개선하였지만 모두 단점이 존재하였다. USLP 의 경우 DNNC 보다 빠른 속도로 학습이 가능하고 비용이 적다. 또한 USLP 는 1 shot 에서는 뛰어난 성능을 보였지만 오히려 5 shot 에서는 기존의 RoBERTa 모델보다도 떨어지는 성능을 보였다. DNNC 모델의 경우 1 shot 문제와 5 shot 모두 RoBERTa 보다 뛰어난 성능을 보였다. 따라서 기존의 자연어 추론 문제를 전이 학습을 통해 모델에 사용하고 자연어 추론 문제에 맞게 서포트셋을 쌍으로 변환하여 학습하는 방법을 이용하려 한다. 최근에 대조 학습을 자연어 처리에 사용하는 논문들이 많이 소개가 되고 있고 있는데 그 중에서도 사전 학습이 끝난 모델이 파인튜닝을 할 때 크로스 엔트로피 손실 함수 대신 지도 대조 손실을 이용한다면 높은 성능 향상을 이끌어 낸다고 한다[4]. 대조 손실을 이용한 다른 논문으로 CPFT[5]가 있고 해당 모델의 경우 현재 퓨샷 의도 분류 모델에서 뛰어난 성능을 보이고 있다. 따라서 자연어 추론 문제를 전이학습한 모델에 지도 대조 손실을 통한 퓨샷 러닝을 적용한 모델(Figure1)을 제안한다.

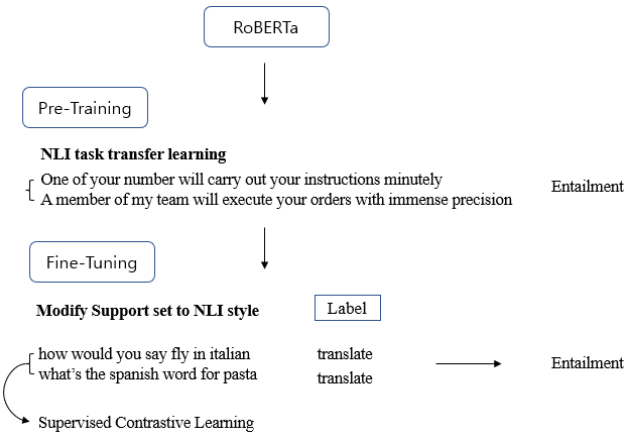

Figure 1 제안 모델 구조

2. 제안 방법

2.1 자연어 추론 쌍 인코딩

본 논문에서는 퓨샷 의도 분류 문제에서의 기존의 RoBERTa 모델과 자연어 추론 문제를 전이학습을 통해 적용한 모델, 퓨샷 러닝에서 지도 대조 손실을 사용한 모델의 성능의 차이를 보인다. RoBERTa 모델은 기존의 BERT 에서 더 큰 배치 사이즈와 더 많은 데이터의 양으로 학습하고 다이나믹 마스킹과 긴 문장을 학습에 사용하여 BERT 에 비해 우월하고 노이즈 강한 모델이다. 기존의 자연어 추론 문제의 경우 쌍으로 이루어진 문장 사이의 의미 관계를 분류하는 문제이다. 레이블은 문장 쌍이 수반될 경우 Entailment, 모순될 경우 Contradiction, 중립이거나 알 수 없을 경우 Neutral 로 분류되지만 해당 모델에서는 이진 분류를 사용하기

때문에 Contradiction 과 Neutral 을 모두 Nonentailment 레이블로 만들어 Entailment 와 Nonentailment 2 가지의 레이블 사용했다. 먼저 자연어 추론 문제의 경우 SNLI, MNLI, WNLI 데이터셋을 사용한다. Table1 에 보이듯이 SNLI 데이터셋은 그림에 대한 캡션으로 이루어진 데이터셋으로 단순한 설명 문장으로 이루어져 있다. MNLI 의 경우 10 가지 장르의 글들로 이루어진 데이터셋으로 여러 장르가 포함되어 있고 자연스러운 문장으로 이루어져 있다. WNLI 데이터셋은 Winograd 문제를 풀기 위한 데이터셋으로 대명사가 가리키는 단어를 탐지하는 데이터셋이다. 추후에 퓨샷 러닝을 할 때에도 서포트 셋을 아래와 같은 자연어 추론 문제 형태로 변환하여 학습을 진행한다.

	Input utterance	Utterance to be compared	Label
SNLI	A person on a horse jumps over a broken down airplain	A person is outdoor, on a horse	Entailment
MNLI	One of your number will carry out your instructions minutely	A member of my team will execute your orders with immense precision	Entailment
WNLI	Steve follows Fred's example in everything. He influences him hugely	Steve influences him hugely	Non entailment

Table 1 자연어추론 데이터셋 예시

2.2 지도 대조 손실

파인 튜닝 단계에서는 서포트 셋의 크기를 5 로 정하여 5-shot learning 을 하였다. 퓨샷 러닝을 하기 위한 서포트 셋으로 CLINC150 데이터셋을 사용하였으며 해당 서포트 셋의 경우 기존의 사전 학습 단계에서는 사용하지 않았다. 서포트 셋을 자연어 추론 문제 형태로 변환하기 위해 문장을 쌍으로 분류하고 같은 의도 클래스에 있는 두 문장을 쌍으로 만들었다면 Entailment, 서로 다른 의도 클래스에 있는 두 문장을 쌍으로 만들었다면 Nonentailment 로 레이블을 달아주었다. 기존의 DNNC 모델와 USLP 모델에서는 이진 크로스 엔트로피 손실함수를 사용하여 파인 튜닝을 하였지만 이 경우 새로운 데이터셋에 빠르게 적응하지 못하고 노이즈에 약하다는 단점이 있다. 퓨샷 러닝의 경우 트레이닝에 사용하는 데이터 셋의 수가 매우 적기 때문에 노이즈에 강인하고 빠르게 일반화하는 것이 중요한데 지도 대조 손실함수를 사용한다면 이진 크로스 엔트로피의 단점을 극복할 수 있다. 지도 대조 손실함수 수식(1)과 같다. 지도 대조 손실함수는 같은 클래스는 가까이, 다른 클래스는 멀리하는 것을 목표로 하고 있는데, 해당 서포트 셋도 이진 분류를 위해 positive(entailment)와 negative (Nonentailment)로 나누어서 positive 는 더 가깝게 negative 는 더 멀리하는 목적이 지도 대조 함수와 일치하여 효과적으로 성능 향상을 이끌어 낸다.

3. 실험 결과

자연어 추론 문제를 전이 학습을 통해 학습하였을 때 성능은 다음 Table2 와 같다. 기존의 RoBERTa 를 이용하였을 때에 대비하여 사전학습 단계에서 자연어 추론 문제를 전이 학습하여 약 4.8%의 성능향상을 보였다. 실험에는 CLINC150 데이터셋의 전체 도메인을 사용하였다.

	Accuracy
RoBERTa	86.2
RoBERTa + NLI	91.6

Table 2 자연어 추론 전이학습에 따른 성능 향상

지도 대조 손실함수를 파인 튜닝에 사용할 때, 데이터의 수가 작을수록 효과적인데 해당 모델에서는 5 개의 labeled 데이터를 사용하기 때문에 성능 향상에 도움이 되었다. 지도 대조 손실함수는 이진 크로스 엔트로피와 함께 사용하며 매개변수 λ값을 통해 지도 대조 손실함수와 이진 크로스 엔트로피 간의 비율을 조절한다. 매개변수 λ값은 0.99, 지도 대조 손실함수를 조절하는 temperature 값인 τ값은 0.3 을 사용하였다.

$$L = (1-\lambda)\, L_{CE} + \lambda\, L_{SCL} \tag{1}$$

$$L_{CE} = -\frac{1}{N}\sum_{i=1}^{N}\sum_{c=1}^{C} y_{i,c} \cdot \log \hat{y}_{i,c} \tag{2}$$

$$L_{SCL} = \sum_{i=1}^{N} -\frac{1}{N_{y_i}-1}\sum_{j=1}^{N} \mathbf{1}_{i\neq j}\mathbf{1}_{y_i=y_j} \log \frac{exp(\Phi(x_i)\cdot\Phi(x_i)/\tau)}{\sum_{k=1}^{N}\mathbf{1}_{i\neq k}\, exp(\Phi(x_i)\cdot\Phi(x_i)/\tau)} \tag{3}$$

지도 대조 손실함수를 사용하였을 때 결과는 Table3 과 같다. 이진 크로스 엔트로피 손실 함수만 사용했을 때에 대비해서 의도의 수가 15 개일 때 약 2.8%, 의도의 수가 150 개일 때는 0.3%의 성능 향상을 보였다. 데이터는 CLINC150 데이터셋을 사용했으며 Banking 도메인만을 사용했을 경우 분류 의도 수가 15 개, 전체 도메인을 사용했을 때 150 개의 분류 의도 수로 실험을 진행했다.

	분류 의도 수	Accuracy	F1 Score
CE	15	91.6	0.95
SCL+ CE	15	94.4	0.96
CE	150	90.7	0.80
SCL+ CE	150	91.0	0.76

Table 3 지도 대조 손실에 따른 성능 향상

4. 결론

본논문에서는 퓨샷 의도 분류 모델의 성능 개선하고자 자연어 추론 문제를 전이학습을 통해 모델의 일반화를 향상시켰고 새로운 서포트 데이터셋을 자연어 추론 문제의 형태로 바꾸어 전이학습의 효과를 높였다. 또한 이진 크로스 엔트로피 소실함수와 지도 대조 손실을 함께 사용하여 학습을 함으로써 쿼리 데이터셋을 더 빨리 학습시켜 모델의 성능을 개선하였다.

ACKNOWLEDGMENT

본 연구는 2022 년 과학기술정통신부 및 정보통신기획평가원의 SW 중심대학사업의 연구결과로 수행되었음 (2022-0-01077).

참 고 문 헌

[1] Yinhan Liu, RoBERTa: A Robustly Optimized BERT Pretraining Approach. arxiv:1907.11692

[2] Jianguo Zhang, Discriminative Nearest Neighbor few-shot intent detection by transferring language inference. EMNLP2020

[3] Jin Qu, Few-Shot Intent Classification by Gauging Entailment Relationship Between Utterance and Semantic Label, ACL workshop 2021

[4] Beliz Gunel, Supervised Contrastive Learning for Pre-trained Language Model Fine-tuning. arXiv:2011.01403

[5] Jianguo Zhang, Few-Shot Intent Detection via Contrastive Pre-Training and Fine-Tuning. EMNLP 2021